




机器学习概述

教学内容

- ▶ 认识机器学习
- ▶ 简单的具体的机器学习问题
 - I. 线性回归
 - II. 线性分类

机器学习 $\approx$ 构建一个映射函数

▶ 语音识别

$$f(\text{  }) = \text{“你好”}$$

▶ 图像识别

$$f(\text{  }) = \text{“猫”}$$

▶ 围棋

$$f(\text{  }) = \text{“5-5” (落子位置)}$$

▶ 对话系统

$$f(\text{“你好”}) = \text{“今天天气真不错”}$$

用户输入

机器

为什么要“机器学习”？


- ▶ 现实世界的问题都比较复杂
- ▶ 很难通过规则来手工实现



2	6	8	9	3	4	7	5	6
3	4	7	9	5	5	6	7	2
5	8	7	0	9	4	3	5	4
5	2	3	4	9	5	6	7	8


什么是机器学习?

- ▶ 机器学习：通过算法使得机器能从大量数据中学习规律从而对新的样本做决策。
- ▶ 规律：决策（预测）函数



独立同分布 $\text{pr}(\mathbf{x}, y)$


e.g., 电影票房预测



回归 (Regression) 问题

评分
导演影响力
演员影响力
电影档期
电影投资方
电影续集
电影制作技术
R-squared
Adjusted R-squared
F-statistic
Prob(F-statistic)

e.g., 股票预测



公司盈利
负债
现金流
销售额
利润率

⇒ 股价

回归 (Regression) 问题

e.g., 房价预测

Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

回归 (Regression) 问题

e.g., 手写数字识别



Fig. 8. All of the misclassified MNIST test digits using our method (63 out of 10,000). The text above each digit indicates the example number followed by the true label and the assigned label.

Belongie et al. PAMI 2002


分类 (Classification) 问题

e.g., 人脸识别



分类 (Classification) 问题


e.g., 垃圾邮件检测



- Classification problem
- $t_i \in \{0, 1\}$, non-spam, spam
- x_i counts of words, e.g. Viagra, stock, outperform, multi-bagger

分类 (Classification) 问题

e.g., 图像聚类



Wang et al., CVPR 2006


- Only x_i is defined: **unsupervised learning**
- E.g. x_i describes image, find groups of similar images

e.g., AlphaGo




强化学习-通过与环境进行交互来学习


e.g.,自动驾驶综合应用场景




常见的机器学习问题



回归



分类



聚类

等等

机器学习的三要素

▶ 模型

▶ 线性模型:

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \mathbf{x} + b$$

▶ 非线性模型:

$$f(\mathbf{x}, \theta) = \mathbf{w}^T \phi(\mathbf{x}) + b$$

▶ 如果 $\phi(\mathbf{x})$ 为可学习的非线性基函数， $f(\mathbf{x}, \theta)$ 就等价于神经网络。

▶ 学习准则

▶ 期望风险

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}), y)],$$

▶ 优化


▶ 梯度下降

模型

▶ 以线性回归（Linear Regression）为例

▶ 模型：

$$f(\mathbf{x}; \mathbf{w}, b) = \mathbf{w}^T \mathbf{x} + b$$



学习准则

▶ 损失函数

▶ 0-1 损失函数

$$\mathcal{L}(y, f(x, \theta)) = \begin{cases} 0 & \text{if } y = f(x, \theta) \\ 1 & \text{if } y \neq f(x, \theta) \end{cases}$$

▶ 平方损失函数

$$\mathcal{L}(y, \hat{y}) = (y - f(x, \theta))^2$$

其他类型的损失函数?

学习准则

► 期望风险未知，通过经验风险近似

► 训练数据： $\mathcal{D} = \{x^{(n)}, y^{(n)}\}, i \in [1, N]$

$$\mathcal{R}_{\mathcal{D}}^{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(x^{(n)}, \theta))$$

► 经验风险最小化



► 在选择合适的风险函数后，我们寻找一个参数 θ^* ，使得经验风险函数最小化。

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\mathcal{D}}^{emp}(\theta)$$

► 机器学习问题转化为一个最优化问题



最优化问题

► 机器学习问题转化成为一个最优化问题



$$\min_{\mathbf{x}} f(\mathbf{x})$$


梯度下降法 (Gradient Descent)



$$\begin{aligned}\theta_{t+1} &= \theta_t - \alpha \frac{\partial \mathcal{R}(\theta)}{\partial \theta_t} \\ &= \theta_t - \alpha \frac{1}{N} \sum_{i=1}^N \frac{\partial \mathcal{L}(\theta_t; x^{(i)}, y^{(i)})}{\partial \theta}.\end{aligned}$$

搜索步长 α 中也叫作学习率 (Learning Rate)

学习率是十分重要的超参数!



随机梯度下降法

- ▶ 随机梯度下降法 (Stochastic Gradient Descent, SGD) 也叫增量梯度下降, 每个样本都进行更新

$$\theta_{t+1} = \theta_t - \alpha \frac{\partial \mathcal{L}(\theta_t; x^{(t)}, y^{(t)})}{\partial \theta},$$

- ▶ 小批量 (Mini-Batch) 随机梯度下降法

随机梯度下降法

算法 2.1: 随机梯度下降法

输入: 训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 验证集 $\mathcal{V}$, 学习率 α

1 随机初始化 θ ;

2 **repeat**

3 对训练集 $\mathcal{D}$ 中的样本随机重排序;

4 **for** $n = 1 \cdots N$ **do**

5 从训练集 $\mathcal{D}$ 中选取样本 $(\mathbf{x}^{(n)}, y^{(n)})$;

 // 更新参数

6 $\theta \leftarrow \theta - \alpha \frac{\partial \mathcal{L}(\theta; x^{(n)}, y^{(n)})}{\partial \theta}$;

7 **end**


8 **until** 模型 $f(\mathbf{x}; \theta)$ 在验证集 $\mathcal{V}$ 上的错误率不再下降;

输出: θ

注意：机器学习！= 优化

机器学习 = 优化？

NO!



过拟合：**经验风险最小化原则**很容易导致模型在训练集上错误率很低，但是在未知数据上错误率很高。

过拟合问题往往是由于训练数据少和噪声等原因造成的。

泛化错误

期望风险


$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}), y)],$$



$\neq$

经验风险

$$\mathcal{R}_D^{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(x^{(n)}, \theta))$$



$$\mathcal{G}_D(f) = \mathcal{R}(f) - \mathcal{R}_D^{emp}(f)$$

泛化错误

如何减少泛化错误?

优化

经验风险最小

正则化

降低模型复杂度



正则化 (regularization)



所有损害优化的方法都是正则化。

增加优化约束

L1/L2约束、数据增强


干扰优化过程

权重衰减、随机梯度下降、提前停止



提前停止

- ▶ 我们使用一个验证集 (Validation Dataset) 来测试每一次迭代的参数在验证集上是否最优。如果在验证集上的错误率不再下降，就停止迭代。





线性回归

线性回归 (Linear Regression)

► 模型:

$$f(\mathbf{x}; \mathbf{w}, b) = \mathbf{w}^T \mathbf{x} + b$$


► 增广权重向量和增广特征向量

$$\hat{\mathbf{x}} = \mathbf{x} \oplus 1 \triangleq \begin{bmatrix} \mathbf{x} \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ 1 \end{bmatrix},$$

$$\hat{\mathbf{w}} = \mathbf{w} \oplus b \triangleq \begin{bmatrix} \mathbf{w} \\ b \end{bmatrix} = \begin{bmatrix} w_1 \\ \vdots \\ w_k \\ b \end{bmatrix},$$



$$f(\mathbf{x}; \hat{\mathbf{w}}) = \hat{\mathbf{w}}^T \hat{\mathbf{x}},$$



经验风险最小化

► 模型

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$$

► 学习准则

$$\begin{aligned}\mathcal{R}(\mathbf{w}) &= \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \mathbf{w})) \\ &= \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - \mathbf{w}^T \mathbf{x}^{(n)} \right)^2 \\ &= \frac{1}{2} \|\mathbf{y} - X^T \mathbf{w}\|^2,\end{aligned}$$

经验风险最小化

► 优化

$$\frac{\partial}{\partial \mathbf{w}} \mathcal{R}(\mathbf{w}) = 0$$

$$\begin{aligned} \frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} &= \frac{1}{2} \frac{\partial \|\mathbf{y} - X^T \mathbf{w}\|^2}{\partial \mathbf{w}} \\ &= -X(\mathbf{y} - X^T \mathbf{w}), \end{aligned}$$

$$\mathbf{w}^* = (X X^T)^{-1} X \mathbf{y}$$

结构风险最小化

▶ 结构风险最小化准则

$$\mathcal{R}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 + \frac{1}{2} \lambda \|\mathbf{w}\|^2,$$

▶ 令 $\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = 0$

$$\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X}\mathbf{y},$$

▶ 岭回归 (Ridge Regression)

关于概率的一些基本概念

▶ 概率 (Probability)

- ▶ 一个随机事件发生的可能性大小，为0到1之间的实数。

▶ 随机变量 (Random Variable)

- ▶ 比如随机掷一个骰子，得到的点数就可以看成一个随机变量 X ，其取值为 $\{1,2,3,4,5,6\}$ 。

▶ 概率分布 (Probability Distribution)

- ▶ 一个随机变量 X 取每种可能值的概率

$$P(X = x_i) = p(x_i), \quad \forall i \in \{1, \dots, n\}.$$

- ▶ 并满足

$$\sum_{i=1}^n p(x_i) = 1,$$

$$p(x_i) \geq 0, \quad \forall i \in \{1, \dots, n\}.$$

概率的一些基本概念

► 伯努利分布 (Bernoulli Distribution)

- 在一次试验中，事件A出现的概率为 μ ，不出现的概率为 $1 - \mu$ 。若用变量X表示事件A出现的次数，则X的取值为0和1，其相应的分布为

$$\square p(x = 1) = \mu;$$

$$\square p(x = 0) = 1 - \mu.$$

$$p(x) = \mu^x (1 - \mu)^{(1-x)}$$

► 二项分布 (Binomial Distribution)

- 在n次伯努利分布中，若以变量X表示事件A出现的次数，则X的取值为 $\{0, \dots, n\}$ ，其相应的分布

$$P(X = k) = \binom{n}{k} \mu^k (1 - \mu)^{n-k}, \quad k = 1 \cdots, n$$

二项式系数，表示从n个元素中取出k个元素而不考虑其顺序的组合的总数。


概率的一些基本概念

- ▶ 连续随机变量 Y 的概率分布一般用概率密度函数 (Probability Density Function , PDF) $p(x)$ 来描述。

$$\int_{-\infty}^{+\infty} p(x)dx = 1$$

- ▶ 高斯分布 (Gaussian Distribution)

$$X \sim \mathcal{N}(\mu, \sigma^2) \quad p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



概率的一些基本概念

► 条件概率 (Conditional Probability)


- 对于离散随机向量 (X, Y) , 已知 $X = x$ 的条件下, 随机变量 $Y = y$ 的条件概率为:

$$p(y|x) = P(Y = y|X = x) = \frac{p(x, y)}{p(x)}$$

► 贝叶斯公式

- 两个条件概率 $p(y|x)$ 和 $p(x|y)$ 之间的关系

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$



例子

		Marginal Probability	
性别\行业	计算机	教育	
男	0.4	0.1	0.5
女	0.1	0.4	0.5
Marginal Probability	0.5	0.5	


$$p(\text{男}|\text{计算机})=?$$

从概率角度来看线性回归

- 假设标签 y 为一个随机变量，其服从以均值为 $f(x; w) = w^T x$ ，方差为 σ^2 的高斯分布。

$$y = f(x, w) + \epsilon$$
$$\epsilon \sim N(0, \sigma^2)$$

$$p(y|x; \mathbf{w}, \sigma) = \mathcal{N}(y; \mathbf{w}^T \mathbf{x}, \sigma^2)$$
$$= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \mathbf{w}^T \mathbf{x})^2}{2\sigma^2}\right).$$



似然函数 (Likelihood)

- ▶ 似然函数是关于统计模型 $p(x;w)$ 的参数 w 的函数
- ▶ 概率 $p(x;w)$ 是描述固定参数 w 时随机变量 x 的分布情况
- ▶ 似然 $p(x;w)$ 则是描述已知随机变量 x 时不同的参数 w 对其分布的影响

线性回归中的似然函数

► 参数 $\mathbf{w}$ 在训练集 D 上的似然函数 (Likelihood) 为

$$\begin{aligned} p(\mathbf{y}|X; \mathbf{w}, \sigma) &= \prod_{n=1}^N p(y^{(n)} | \mathbf{x}^{(n)}; \mathbf{w}, \sigma) \\ &= \prod_{n=1}^N \mathcal{N}(y^{(n)}; \mathbf{w}^\top \mathbf{x}^{(n)}, \sigma^2) \end{aligned}$$

最大似然估计

▶ 最大似然估计 (Maximum Likelihood Estimate, MLE)

▶ 是指找到一组参数 $\mathbf{w}$ 使得似然函数 $p(\mathbf{y}|\mathbf{X}; \mathbf{w}, \sigma)$ 最大

$$\text{令 } \frac{\partial \log p(\mathbf{y}|\mathbf{X}; \mathbf{w}, \sigma)}{\partial \mathbf{w}} = 0$$



贝叶斯视角

▶ 贝叶斯学习

▶ 将参数 w 也看作随机变量

▶ 目标：给定一组观测数据 X ，求参数 w 的分布 $p(w|X)$

▶ $p(w|X)$

后验分布

贝叶斯公式：

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$p(w|x) \propto p(x|w)p(w)$$

后验
posterior

似然
likelihood

先验
prior

$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

贝叶斯估计(Bayesian Estimation)

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}; \nu, \sigma) = \frac{p(\mathbf{w}, \mathbf{y}|\mathbf{X}; \nu, \sigma)}{\sum_{\mathbf{w}} p(\mathbf{w}, \mathbf{y}|\mathbf{X}; \nu, \sigma)} \\ \propto \underbrace{p(\mathbf{y}|\mathbf{X}, \mathbf{w}; \sigma)}_{\text{似然}} \underbrace{p(\mathbf{w}; \nu)}_{\text{先验}},$$

后验
posterior

似然
likelihood

先验
prior

$$p(\mathbf{w}; \nu) = \mathcal{N}(\mathbf{w}; \mathbf{0}, \nu^2 I)$$

$$\log p(\mathbf{w}|\mathbf{X}, \mathbf{y}; \nu, \sigma) \propto \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}; \sigma) + \log p(\mathbf{w}; \nu)$$

$$\propto -\frac{1}{2\sigma^2} \sum_{n=1}^N \left(y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)} \right)^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w},$$

$$= -\frac{1}{2\sigma^2} \underbrace{\|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2}_{\text{}} - \frac{1}{2\nu^2} \underbrace{\mathbf{w}^\top \mathbf{w}}_{\text{}}.$$

正则化系数 $\lambda = \sigma^2/\nu^2$

最大后验估计 (Maximum A Posteriori Estimation, MAP)

- ▶ 贝叶斯估计是一种参数的区间估计，即参数在一个区间上的分布
- ▶ 如果希望得到一个最优的参数值，可以使用MAP

$$\mathbf{w}^{MAP} = \arg \max_{\mathbf{w}} p(\mathbf{y}|\mathbf{X}, \mathbf{w}; \sigma) p(\mathbf{w}; \nu)$$

$$\mathbf{w}^{MAP} = -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w} \quad \text{正则化系数 } \lambda = \sigma^2/\nu^2$$

总结

	无先验	引入先验
平方误差	经验风险 最小化	结构风险 最小化
概率	最大似然估计	最大后验估计


$$(XX^T)^{-1}Xy$$

$$(XX^T + \lambda I)^{-1}Xy$$




线性分类

线性分类模型



$$g(f(\mathbf{x}; \mathbf{w})) = \begin{cases} 1 & \text{if } f(\mathbf{x}; \mathbf{w}) > 0 \\ 0 & \text{if } f(\mathbf{x}; \mathbf{w}) < 0 \end{cases}$$



线性分类模型 = 线性判别函数 + 线性决策边界

二/多分类

▶ 训练集: $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$


▶ 二分类 (多分类呢?)

▶ $\mathbf{x}^{(n)}$


▶ $y^{(n)}$

▶ 模型:


$$g(f(\mathbf{x}; \mathbf{w})) = \begin{cases} 1 & \text{if } f(\mathbf{x}; \mathbf{w}) > 0 \\ 0 & \text{if } f(\mathbf{x}; \mathbf{w}) < 0 \end{cases}$$



(a) “一对其余”方式



(b) “一对一”方式



(c) “argmax”方式

▶ 损失函数?

线性模型

- ▶ Logistic 回归
- ▶ Softmax 回归

补充知识：信息论 (Information Theory)

► 在信息论中，熵 (Entropy) 用来衡量一个随机事件的不确定性。

► 自信息 (Self Information)

$$I(x) = -\log(p(x))$$

► 熵

$$H(X) = \mathbb{E}_X[I(x)]$$

$$= \mathbb{E}_X[-\log p(x)]$$

$$= - \sum_{x \in \mathcal{X}} p(x) \log p(x)$$

► 熵越高，则随机变量的信息越多；

► 熵越低，则随机变量的信息越少。E.g., applicatio_, appl_

► 在对分布 $q(y)$ 的符号进行编码时，熵 $I(q)$ 也是理论上最优的平均编码长度，这种编码方式称为熵编码 (Entropy Encoding)

交叉熵 (Cross Entropy)


- ▶ 交叉熵是按照概率分布 q 的最优编码对真实分布为 p 的信息进行编码的长度。

$$\begin{aligned} H(p, q) &= \mathbb{E}_p[-\log q(x)] \\ &= -\sum_x p(x) \log q(x) \end{aligned}$$

- ▶ 在给定 q 的情况下，如果 p 和 q 越接近，交叉熵越小；
- ▶ 如果 p 和 q 越远，交叉熵就越大。

KL散度 (Kullback-Leibler Divergence)

- ▶ **KL散度是用概率分布q来近似p时所造成的信息损失量。**
- ▶ KL散度是按照概率分布q的最优编码对真实分布为p的信息进行编码，其平均编码长度（即交叉熵） $H(p,q)$ 和p的最优平均编码长度（即熵） $H(p)$ 之间的差异。



$$\begin{aligned} \text{KL}(p, q) &= H(p, q) - H(p) \\ &= \sum_x p(x) \log \frac{p(x)}{q(x)} \end{aligned}$$

交叉熵损失

$$D_{KL}(p_r(y|x)||p_\theta(y|x)) = \sum_{y=0}^1 p_r(y|x) \log \frac{p_r(y|x)}{p_\theta(y|x)} \quad \text{KL散度}$$

$$\propto - \sum_{y=0}^1 p_r(y|x) \log p_\theta(y|x) \quad \text{交叉熵损失}$$

y^* 为 x 的真实标签

$$= -I(y^* = 1) \log p_\theta(y = 1|x) - I(y^* = 0) \log p_\theta(y = 0|x)$$

$$= -y^* \log p_\theta(y = 1|x) - (1 - y^*) \log p_\theta(y = 0|x)$$


$$= -\log p_\theta(y^*|x) \quad \text{负对数似然}$$

Logistic Regression

► 模型

$$g(f(\mathbf{x}; \mathbf{w})) = \begin{cases} 1 & \text{if } f(\mathbf{x}; \mathbf{w}) > 0 \\ 0 & \text{if } f(\mathbf{x}; \mathbf{w}) < 0 \end{cases}$$

损失函数?



分类问题

▶ 将分类问题看作条件概率估计问题

▶ 引入非线性函数 g 来预测类别标签的条件概率 $p(y = c|x)$ 。

▶ 以二分类为例，

$$p(y = 1|\mathbf{x}) = g(f(\mathbf{x}; \mathbf{w}))$$

▶ 函数 f : 线性函数


▶ 函数 g : 把线性函数的值域从实数区间“挤压”到了 $(0,1)$ 之间，可以用来表示概率。

如何构造函数 g ?

Logistic函数与回归

► Logistic函数

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$



Sigmoid型，
单调递增，
两端饱和

► Logistic回归

$$p(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x}) \quad p_\theta(y = 1|\mathbf{x})$$
$$\triangleq \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})}$$

学习准则

▶ 模型预测条件概率 $p_{\theta}(y|\mathbf{x})$

$$p_{\theta}(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$$

▶ 真实条件概率 $p_r(y|\mathbf{x})$

▶ 对于一个样本 $(\mathbf{x}, y^*)$, 其真实条件概率为

$$\begin{aligned} p_r(y = 1|\mathbf{x}) &= y^* \\ p_r(y = 0|\mathbf{x}) &= 1 - y^* \end{aligned}$$

$$\begin{aligned} y^* &= 1; \quad \text{Pr} \\ y^* &= 0; \quad \text{Pr} \end{aligned}$$

如何衡量两个条件分布的差异?

$$H(p_r, p_{\theta}) = -\left(y^* \log \hat{y} + (1 - y^*) \log(1 - \hat{y})\right)$$

梯度下降

► 交叉熵损失函数，模型在训练集的风险函数为

$$\mathcal{R}(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N \left(y^{(i)} \log \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) + (1 - y^{(i)}) \log \left(1 - \sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) \right).$$

这里为了演示方便，
省略了正则项

► 梯度为


$$\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{N} \sum_{i=1}^N \left(\mathbf{x}^{(i)} \cdot \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) - y^{(i)} \right) \right)$$

► 迭代更新

$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \alpha \frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \left(y^{(n)} - \hat{y}_{\mathbf{w}_t}^{(n)} \right)$$

$$\begin{aligned}
\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} &= -\frac{1}{N} \sum_{n=1}^N \left(y^{(n)} \frac{\hat{y}^{(n)}(1 - \hat{y}^{(n)})}{\hat{y}^{(n)}} \mathbf{x}^{(n)} - (1 - y^{(n)}) \frac{\hat{y}^{(n)}(1 - \hat{y}^{(n)})}{1 - \hat{y}^{(n)}} \mathbf{x}^{(n)} \right) \\
&= -\frac{1}{N} \sum_{n=1}^N \left(y^{(n)}(1 - \hat{y}^{(n)}) \mathbf{x}^{(n)} - (1 - y^{(n)}) \hat{y}^{(n)} \mathbf{x}^{(n)} \right) \\
&= -\frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} (y^{(n)} - \hat{y}^{(n)}).
\end{aligned}$$

Logistic回归



Softmax回归

► 多分类问题

$$y = \arg \max_{c=1}^C f_c(\mathbf{x}; \mathbf{w}_c)$$

► Softmax函数

$$\text{softmax}(x_k) = \frac{\exp(x_k)}{\sum_{i=1}^K \exp(x_i)}$$

	A	B	C
1	x	exp(x)	softmax(x)
2		-2 0.135335283	0.000894679
3		1 2.718281828	0.017970118
4		5 148.4131591	0.981135202
5	sum(exp(x))	151.2667762	知乎 @老杜

► 利用softmax函数，目标类别 $y = c$ 的条件概率为：

$$\begin{aligned} P(y = c | \mathbf{x}) &= \text{softmax}(\mathbf{w}_c^T \mathbf{x}) \\ &= \frac{\exp(\mathbf{w}_c^T \mathbf{x})}{\sum_{i=1}^C \exp(\mathbf{w}_i^T \mathbf{x})} \end{aligned}$$

交叉熵损失函数

▶ 负对数似然损失函数

$$\mathcal{L}(\mathbf{y}, f(\mathbf{x}, \theta)) = - \sum_{c=1}^C y_c \log f_c(\mathbf{x}, \theta)$$

▶ 对于一个三类分类问题，类别为[0,0,1]，预测类别概率为[0.3,0.3,0.4]，则

$$\begin{aligned}\mathcal{L}(\theta) &= -(0 \times \log(0.3) + 0 \times \log(0.3) + 1 \times \log(0.4)) \\ &= -\log(0.4).\end{aligned}$$

参数学习

► 模型：Softmax 回归

► 学习准则：交叉熵

$$\mathcal{R}(W) = -\frac{1}{N} \sum_{n=1}^N (\mathbf{y}^{(n)})^T \log \hat{\mathbf{y}}^{(n)}$$

► 优化：梯度下降

$$\frac{\partial \mathcal{R}(W)}{\partial W} = -\frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \left(\mathbf{y}^{(n)} - \hat{\mathbf{y}}^{(n)} \right)^T$$



谢谢！