

# 第一章 自然语言处理概述

# 本课程目标

---



了解自然语言处理的基本概念



了解自然语言处理技术面临的困难



了解自然语言处理的主要研究任务和应用



掌握自然语言处理开发环境搭建

# 课程目录

Course catalogue

1/ 自然语言处理的基本概念

2/ 自然语言处理技术面临的困难

3/ 自然语言处理的主要研究任务和应用

4/ 自然语言处理开发环境搭建

# 自然语言处理的基本概念

## 自然语言处理 (NLP)

自然语言理解 (NLU)

自然语言生成 (NLG)

## 什么是自然语言处理


自然语言处理 (Natural Language Processing, NLP) 是语言学、计算机科学和人工智能的一个分支，研究使用计算机自动（或半自动）地处理、理解、分析、以及运用人类语言。它主要研究人与计算机之间，使用自然语言进行有效通信的各种理论和方法。其目标是让计算机能够“理解”自然语言，代替人类执行语言翻译和问题回答等任务。简单来说，计算机以用户的自然语言形式作为输入，在其内部通过定义的算法进行加工、计算等一系列操作后（用以模拟人类对自然语言的理解），再返回用户所期望的结果。

# 自然语言处理的基本概念

## 自然语言处理的层次

自然语言的理解和分析是一个层次化的过程，分为以下**5个层次**：

- 语音分析是要根据音位规则，从语音流中区分出一个个独立的音素，再根据音位形态规则找出音节及其对应的词素或词。
- 词法分析是找出词汇的各个词素，从中获得语言学的信息。
- 句法分析是对句子和短语的结构进行分析，目的是要找出词、短语等的相互关系以及各自在句中的作用。
- 语义分析是找出词义、结构意义及其结合意义，从而确定语言所表达的真正含义或概念。
- 语用分析是研究语言所存在的外界环境对语言使用者所产生的影响。



# 自然语言处理的基本概念

---

## 判别标准



在人工智能领域或者是语音信息处理领域中，学者们普遍认为采用图灵试验可以判断计算机是否理解了某种自然语言，具体的判别标准有以下几条：

- 问答，机器人能正确回答输入文本中的有关问题；
- 文摘生成，机器有能力生成输入文本的摘要；
- 释义，机器能用不同的词语和句型来复述其输入的文本；
- 翻译，机器具有把一种语言翻译成另一种语言的能力。

# 自然语言处理的基本概念

## 自然语言处理的发展历程

### 大语言模型时代（2017-至今）



# 课程目录

Course catalogue

1/ 自然语言处理的基本概念

2/ 自然语言处理技术面临的困难

3/ 自然语言处理的主要研究任务和应用

4/ 自然语言处理开发环境搭建

# 自然语言处理技术面临的困难

## 歧义：词法层面

例1 两~~个~~/人/一起/过去、~~个~~人/问题

从~~马~~/上/下来、~~马~~上/就/来

例2 下雨天留客天留人不留（姑姑对过儿说过过我也想过过过过过过的生活）

有多种划分，如下：

- 1) 下雨天，留客天，留人不留？
- 2) 下雨天，留客天，留人不？留。
- 3) 下雨天留客，天留人不留。

例3 I saw a man in the park with a telescope.

这句话可以理解为：

- 1) 我在公园里看到一个拿着望远镜的男人。
- 2) 我用望远镜看到有一个男人在公园里。
- 3) 我在公园里用望远镜看到一个男人。

# 自然语言处理技术面临的困难

例4 做手术的是张老师。

这句话有两种理解方式：

一是张老师得病了，需要做手术；

二是有病人需要做手术，张老师是主刀医生。

歧义：句法层面

歧义：语义层面

例5

灵魂八问

配钥匙师傅：你配吗？

食堂阿姨：你要饭吗？

算命先生：你算什么东西？

快递小哥：你是什么东西？

上海垃圾分类阿姨：你是什么垃圾？

滴滴司机：你搞清楚你自己的定位了么？

理发师傅：你自己照照镜子看看你自己，觉得还行么？

小区保安：你是谁？你从哪里来？要到哪里去？

# 自然语言处理技术面临的困难

## 知识获取、表达及运用

**例6** 小张欺负小李，因此我批评了他。

在理解上面这句话的时候，后半句中的“他”指的是小张还是小李，需要通过上下文来确定，“小张欺负小李”意味着小张做的不对，因此这个“他”应当指代的是小张。

**例7** 请看以下对话：

女生：就算你给我买个包，我也不会原谅你的。

男生：好的好的，我不会买的，不要生气了好吧。

看完以上对话，您认为这个女生还会不会生气呢？

除了这些难题，还有哪些呢？

# 自然语言处理技术面临的困难

## UTF-8编码

中国: E4B8AD E59BBD

首都: E9A696 E983BD

北京: E58C97 E4BAAC

## 计算问题

自然语言处理的发展除了受语言学的制约外，在计算角度也存在天然的局限性。现有的计算机都以浮点数作为输入和输出，擅长执行算术类运算。而自然语言本身并不是数字，计算机为了能存储和显示自然语言，需要按照某种格式把自然语言中的字符转换为二进制编码。由于这个编码本身不是数字，对这个编码的计算往往不具备数学和物理含义。

# 课程目录

Course catalogue

1/ 自然语言处理的基本概念

2/ 自然语言处理技术面临的困难

3/ 自然语言处理的主要研究任务和应用

4/ 自然语言处理开发环境搭建

# 自然语言处理的主要研究任务和应用


## 序列标注

分词  
我爱自然语言处理 → 我爱/自然语言/处理

词性标注  
去颐和园玩 → 去/v 颐和园/nt 玩/v

- 分词：词是最小的、能够独立使用的、有意义的语言成分。
- 词性标注：词性标注就是在分词的基础上，判定每个词的语法范畴，确定其词性并加以标注的过程。
- 命名实体识别：简单来说命名实体识别问题就是将一段文本序列中包含的实体识别出来。

# 自然语言处理的主要研究任务和应用



## 分类

- 文本分类：文本分类是指在给定的分类体系中，将文本指定到某个或某几个类别中。
- 情感倾向分析：从本质上看，文本情感分析也是分类问题，是对带有情感色彩（通常指褒义/贬义、正向/负向）的主观性文本进行分析，以确定该文本的观点、喜好、情感倾向。



# 自然语言处理的主要研究任务和应用

## 关系判断

- 文本相似计算：在信息爆炸时代，人们迫切希望从海量信息中获取与自身需要和兴趣吻合度高的内容，为了满足此需求，出现了多种技术，如：搜索引擎、推荐系统、问答系统、文档分类与聚类、文献查重等，而这些应用场景的关键技术之一就是文本相似度计算技术。
- 自然语言推理：自然语言推理研究一个假设是否可以从一个前提中推断出来，前提和假设都是文本序列。换句话说，自然语言推理决定了一对文本序列之间的逻辑关系。

# 自然语言处理的主要研究任务和应用



## 自然语言生成

- 机器翻译：机器翻译就是利用计算机将一种自然语言（源语言）转换为另一种自然语言（目标语言）的过程；
- 文本摘要：随着互联网产生的文本数据越来越多，文本信息过载问题日益严重，文本摘要的目标是将长文本进行压缩、归纳和总结，从而形成具有概括性含义的短文本。

# 自然语言处理的主要研究任务和应用

## 自然语言处理的典型应用

- 语音识别：语音识别的应用已经非常的普及，微信里可以语音转文字，可以使用语音为手机发送指令，汽车中使用导航可以直接说目的地，老年人使用输入法也可以直接用语音而不用学习拼音；
- 机器翻译：机器翻译是NLP中比较常见的应用场景，国内外有很多比较成熟的机器翻译产品，如百度翻译、Google翻译等，还有支持语音输入的多国语言互译的硬件产品；
- 聊天机器人：客户服务和用户体验对于任何公司来说都是非常重要的事情。它可以帮助公司改进其产品，提升客户满意。但是，与客户进行手动交互并解决问题可能是一项繁琐的任务。许多公司已经将聊天机器人用于其应用程序和网站，解决客户的一些基本问题；
- 自动更正和自动完成：当我们在百度或Google搜索某个内容，在输入几个字后，它会显示可能的搜索词。或者，搜索一些有错别字的内容，它会更正它们，仍然会找到适合的相关结果；
- 社交媒体监控：如今，越来越多的人开始使用社交媒体发布对某些产品、政策或社会事件的看法。这些信息有可能包含一些不健康的内容，可以使用NLP技术对这些内容进行自动检测。

# 课程目录

Course catalogue

- 1/ 自然语言处理的基本概念
- 2/ 自然语言处理技术面临的困难
- 3/ 自然语言处理的主要研究任务和应用
- 4/ 自然语言处理开发环境搭建



## Anaconda

- Anaconda附带了一大批常用数据科学包，包括 conda、Python 和 180 多个科学包及其依赖项，因此可以立即开始自己的项目；
- Anaconda 是在 conda（一个包管理器和环境管理器）上发展出来的。在数据分析中会用到很多第三方的包，而conda可以很好地帮助我们在计算机上安装和管理这些包，包括安装、卸载和更新包；
- 可以在电脑上创建多个python环境，并为每个python环境安装不同的包，不同环境互不影响、相互切换，操作简单。



## scikit-learn

scikit-learn, 又写作sklearn, 是一个开源的基于python语言的机器学习工具包。它通过NumPy、SciPy和Matplotlib等python数值计算的库实现高效的算法应用, 它包含了从数据预处理到训练模型的各个方面。在实际应用中, 使用scikit-learn可以极大地节省编写代码的时间以及减少代码量, 使我们有更多的精力去分析数据分布、调整模型和修改超参数。

# 自然语言处理开发环境搭建

---

## Jupyter notebook

Jupyter Notebook是基于网页的用于交互计算的应用程序，可被应用于全过程计算，包括：编写文档、运行代码和展示结果等。



结束

---

谢谢