



https://www.bilibili.com/video/BV1wdL2zxEsb/?vd_source=646011d46b009c60b57f09c29e00ee0f

第三章 句法分析

本课程目标



理解句法分析的基本概念



理解概率上下文无关文法



理解依存句法分析



掌握中文句法分析工具的使用



Tower of Babel

「巴别塔」的传说

「世界上本来只有一种语言，人们说着同样的话。他们想建一座通天塔。上帝说：他们同文同语，如今就做这事，以后就没有他们做不成的事了。」

— 创世纪 11:1-9

- ▶ 全人类共语，计划建造通天塔
- ▶ 上帝打散语言，人类从此分离
- ▶ **「Babel」：混乱、分散**
- ▶ 现存人类语言：7000+ 种

语言混乱的起源

7000+ 种语言，语法各不相同

人类建立语言规则

词山、词组、主谓宾结构

计算机自动句法分析

让机器“理解”语言结构

自然语言处理 / NLP 核心技术系列

句法分析

Syntactic Parsing

巴别塔的传说告诉我们：语言差异是人类互相理解的最大障碍。
要打破这一障碍，我们首先需要让计算机 **「看懂」语言的结构**。

本课内容概览

01

什么是句法分析

02

主流方法与实例

03

传统方法原理

04

深度学习 & 大模型时代

自然语言处理

句法分析

Syntactic Parsing

01

什么是句法分析

02

主流方法与实例

03

传统方法原理

04

深度学习 & 大模型时代

什么是句法分析？

分析词与词之间的语法关系——句子的结构骨架

定义：句法分析（Syntactic Parsing）是对句子的语法结构进行自动分析，揭示词与词之间的语法依存关系，回答「谁是主语、谁修饰谁、哪些词构成一个短语」等问题。

我 爱 自然语言处理

主谓宾 + 修饰关系 → 完整语义骨架

他昨天买的那本书很好看

「好看」的逻辑主语跨越多个词 → 长距离依存

I saw a person using a telescope.

歧义：「用望远镜」修饰「我」还是「人」？

为什么句法分析很重要？

理解语言结构是许多 NLP 任务的基础



信息抽取

提取「谁 → 做了什么 → 对谁」三元组关系
依赖主谓宾结构定位关键信息



机器翻译

理解源语言句法结构
生成目标语言正确的语序与成分



问答系统

分析疑问句结构
判断问的是「谁」「何时」「在哪」



情感分析

「这部电影不好看」

不懂句法的模型怎么做？

最简单的情感分析模型就是数正面词和负面词：

看到「好看」→ 正面词 ✓

结论：正面情感 ✗ 判断错了！

避免因忽视否定结构导致误判



语法纠错

检测句子结构是否合法
定位缺少主语、谓语不匹配等错误



对话系统

“把红色的球移到蓝色盒子的左边”


理解用户指令的语义角色

正确执行「把A移到B旁边」类命令

句法分析的两大主流范式

成分句法 vs 依存句法——各有侧重，各有优势

成分句法分析 Constituency Parsing




输出: 短语结构树

特点: 层级嵌套，揭示短语边界

算法: CYK、Earley、神经成分分析

依存句法分析 Dependency Parsing



输出: 依存关系树

特点: 词对词关系，更轻量直接

算法: 基于转移 (arc-eager)、图算法 (Biaffine)

自20世纪90年代以来，随着语料资源的获取变得容易，基于统计的方法开始在自然语言处理领域成为主流。这种方法采用统计学的处理技术从大规模语料库中获取语言分析所需要的知识，放弃人工干预，减少对语言学家的依赖。它的基本思想是：

- (1) 使用语料库作为唯一的信息源，所有的知识（除了统计模型的构造方法）都是从语料库中获得；
- (2) 语言知识在统计意义上被解释，所有参数都是通过统计处理从语料库中自动获得的。基于统计的方法具有效率高、鲁棒性强的优点，大量的实验已经证明了该方法的优越性。


PCFG简介

目前，统计方法已经被句法分析的研究者普遍采用。为进行统计句法分析，首先要遵循某一语法体系，根据该体系的语法确定语法树的表示形式。目前，在句法分析中使用比较广泛的有短语结构语法和依存语法。当前短语结构句法分析普遍基于概率上下文无关文法（probabilistic context free grammar, PCFG）。

自二十世纪八十年代以来，各国学者对PCFG模型进行了非常深入的研究，是目前研究得最为充分、形式最为简单的统计句法分析模型。PCFG具有形式简洁、参数空间小和分析效率高等特点，且形成了较完整的体系。

PCFG

树，自顶向下，Derivation



相似



形式句法->上下文无关语法

Context Free Grammars (CFG)

$\langle N, \Sigma, R, S \rangle$


N : non-terminals, 对应非叶子结点 (A)

Σ : terminals, 对应叶子结点 (γ)

R : production rules, 对应生成规则($A \rightarrow \gamma$)

S : start symbols, 对应起点, 句子 (S)

Derivation



$S \rightarrow \text{ADVP } S^*, \text{ADVP} \rightarrow \text{RB}, S^* \rightarrow$
 $S^*., S^* \rightarrow \text{VP } \text{NP}, \text{VP} \rightarrow \text{VBP}, \text{NP} \rightarrow$
 $\text{NP } \text{PP}, \text{NP} \rightarrow \text{DT } \text{NP}^*, \text{NP}^* \rightarrow$
 $\text{JJ } \text{NNS}, \text{PP} \rightarrow \text{IN } \text{NP}, \text{NP} \rightarrow \text{DT } \text{NNS}$
 $\text{RB} \rightarrow \text{Here}, \text{VBP} \rightarrow \text{are}, \text{DT} \rightarrow$
 $\text{the}, \text{JJ} \rightarrow \text{net}, \text{NNS} \rightarrow \text{contributions},$
 $\text{IN} \rightarrow \text{of}, \text{NNS} \rightarrow \text{experts}$

基于PCFG的句法分析

$P(S \Rightarrow \text{Here are the net contributions of the experts.})$

$P(S \rightarrow \text{ADVP } S^*)P(\text{ADVP} \rightarrow \text{RB})P(S^* \rightarrow S^*.)P(S^* \rightarrow \text{VP NP})P(\text{VP} \rightarrow \text{VBP})P(\text{NP} \rightarrow \text{NP PP})P(\text{NP} \rightarrow \text{DT NP}^*)P(\text{NP}^* \rightarrow \text{JJ NNS})P(\text{PP} \rightarrow \text{IN NP})P(\text{NP} \rightarrow \text{DT NNS})P(\text{RB} \rightarrow \text{Here})P(\text{VBP} \rightarrow \text{are})P(\text{DT} \rightarrow \text{the}, \text{JJ} \rightarrow \text{net})P(\text{NNS} \rightarrow \text{contributions})P(\text{IN} \rightarrow \text{of})P(\text{NNS} \rightarrow \text{experts})$

基于PCFG的句法分析

基于概率上下文无关文法（PCFG）的句法分析方法既有规则方法的特点，又运用了概率信息，因此，可以认为是规则方法与统计方法的紧密结合。尤其在最近几年，随着统计方法研究的不断升温 and 统计方法必须与规则方法相结合的观点得到普遍认同，基于PCFG的句法分析方法研究备受关注。

$$P(\alpha \xRightarrow{A \rightarrow \gamma} \beta) = P(A \rightarrow \gamma) = P(\gamma|A)$$

$$D = \{(W_i, T_i)\}_{i=1}^N$$

$$P(\gamma|A) = P(A \rightarrow \gamma) = \frac{\text{count}(A \rightarrow \gamma)}{\text{count}(A)}$$

$$= \frac{\sum_{i=1}^N \text{count}(A \rightarrow \gamma, T_i)}{\sum_{i=1}^N \text{count}(A, T_i)}$$

课堂练习， 书本P61页

$S \rightarrow \text{astronomers saw stars with ears}$
 $P(S)$

基于PCFG的句法分析

根据上述文法，句子He met Jenny with flowers有两个可能的句法结构。

在基于PCFG的句法分析模型中，假设满足以下三个条件

- ① 位置不变性 (place invariance)：子树的概率不依赖于该子树所管辖的单词在句子中的位置；
- ② 上下文无关性 (context-free)：子树的概率不依赖于子树控制范围以外的单词；
- ③ 祖先无关性 (ancestor-free)：子树的概率不依赖于推导出子树的祖先结点。

基于PCFG的句法分析

基于PCFG的句法分析

与HMM类似，PCFG也有三个基本问题：

- ① 给定一个句子 $W=w_1w_2 \dots w_n$ 和文法 G ，如何快速计算概率 $P(W|G)$ ？
- ② 给定一个句子 $W=w_1w_2 \dots w_n$ 和文法 G ，如何选择该句子的最佳结构？即选择句法结构树 t 使其具有最大概率：
 $\operatorname{argmax}_t P(t|W, G)$ ；
- ③ 给定PCFG G 和句子 $W=w_1w_2 \dots w_n$ ，如何调节 G 的概率参数，使句子的概率最大？即求解 $\operatorname{argmax}_G P(t|W, G)$

为了便于描述解决这三个问题的算法，我们在这里只考虑文法具有乔姆斯基范式（Chomsky normal form, CNF）的情况，即文法规则只有以下两种形式：


- ① $A \rightarrow a$ ； a 为终结符号；
- ② $A \rightarrow BC$ ； $B、C$ 为非终结符号。

任意给定一个CFG，都可以将其转换为CNF文法。假定文法符合CNF形式并不影响下面将要介绍的算法的适用性。这些算法只作适当的修改，便可用于其他形式的上下文无关文法。

依存句法分析简介

依存语法理论

依存句法认为“谓语”中的动词是一个句子的中心，其他成分与动词直接或间接地产生联系。“依存”指词与词之间支配与被支配的关系，这种关系不是对等的、具有方向的。确切的说，处于支配地位的成分称之为支配者，而处于被支配地位的成分称之为从属者。依存语法本身没有规定要对依存关系进行分类，但为了丰富依存结构传达的句法信息，在实际应用中，一般会给依存树的边加上不同的标记。各种依存语法存在一个共同的基本假设：句法结构本质上包含词和词对之间的关系。这种关系称为依存关系（dependency relations，或 dependencies）。一个依存关系连接两个词，分别是核心词（head）和修饰词（dependent）。



依存句法分析分类

依存句法分析分类

依存句法分析的方法主要可以分为基于图模型（Graph-based model）的分析方法和基于转移模型（Transition-based model）的分析方法。

基于图模型的方法将依存句法分析视作一个在完全有向图中寻找最大生成树的问题；而基于转移模型的方法则是通过一个移进规约转移动作序列构建一棵句法树，将依存句法分析问题转化为寻找一个最优动作序列的问题。

实例：依存句法分析

句子「张伟在北京大学参加了百度举办的比赛」

张伟	在	北京大学	参加	了	百度	举办	的	比赛
<i>nsubj</i>	<i>prep</i>	<i>pobj</i>	<i>ROOT</i>	<i>asp</i>	<i>nsubj</i>	<i>rcmod</i>	<i>dec</i>	<i>dobj</i>

依存关系解读

nsubj (主语) 张伟 → 参加 张伟是「参加」的主语	pobj (介词宾语) 北京大学 → 在 北京大学是「在」的宾语
dobj (宾语) 比赛 → 参加 比赛是「参加」的直接宾语	rcmod (关系从句) 举办 → 比赛 「谷歌举办的」修饰「比赛」
prep (介词短语) 在 → 参加 「在北京大学」是「参加」的状语	nsubj (从句主语) 百度 → 举办 百度是从句「举办」的主语

中文句法分析工具介绍

中文句法分析工具介绍

目前，随着关于句法分析的研究不断深入，已经涌现了许多优秀的句法分析工具。其中，支持中文句法分析的工具具有Stanford Parser、Berkeley parser，以及哈工大LTP等。

中文句法分析工具介绍


中文句法分析工具介绍

Stanford NLP是由斯坦福大学的NLP小组开源的Java实现的自然语言处理工具包，对自然语言处理领域的各个问题提供了解决办法，包括分词、词性标注、命名实体识别、句法分析，以及依存句法分析。Stanford parser

(<https://nlp.stanford.edu/software/lex-parser.html>)中实现了高度优化的PCFG句法分析器以及依存句法分析器。Stanford Parser的Python封装基于NLTK实现，关于NLTK的安装与配置此处不再赘述。另外，需要注意的是Stanford Parser对于JDK版本有一定的要求（目前，对JDK版本的要求是1.8以上）。如果在导入Stanford Parser时出现错误，读者可尝试安装最新版本的JDK，并在安装后重新配置环境变量中的JAVA HOME。

```
string = '东京2020年奥运会组委会和国际奥委会达成协议'
seg_list = jieba.cut(string, cut_all=False, HMM=True)
seg_str = ''.join(seg_list)
print(seg_str)
```

东京 2020 年 奥运会 组委会 和 国际奥委会 达成协议



中文句法分析工具介绍


中文句法分析工具介绍

哈工大语言技术平台（Language Technology Platform, LTP）是哈尔滨工业大学社会计算与信息检索研究中心开发的一整套中文语言处理系统。LTP还提供了包括中文分词、词性标注、命名实体识别、依存句法分析、语义角色标注等NLP技术。

哈工大语言云演示平台：<http://www.ltp-cloud.com/>

GitHub代码：<https://github.com/HIT-SCIR/pyltp>

文档：https://pyltp.readthedocs.io/zh_CN/latest/



依存句法关系			
关系类型	Tag	Description	Example
主谓关系	SBV	subject-verb	我送她一束花 (我 <- 送)
动宾关系	VOB	直接宾语, verb-object	我送她一束花 (送 -> 花)
间宾关系	IOB	间接宾语, indirect-object	我送她一束花 (送 -> 她)
前置宾语	FOB	前置宾语, fronting-object	他什么书都读 (书 <- 读)
兼语	DBL	double	他请我吃饭 (请 -> 我)
定中关系	ATT	attribute	红苹果 (红 <- 苹果)
状中结构	ADV	adverbial	非常美丽 (非常 <- 美丽)
动补结构	CMP	complement	做完了作业 (做 -> 完)
并列关系	COO	coordinate	大山和大海 (大山 -> 大海)
介宾关系	POB	preposition-object	在贸易区内 (在 -> 内)
左附加关系	LAD	left adjunct	大山和大海 (和 <- 大海)
右附加关系	RAD	right adjunct	孩子们 (孩子 -> 们)
独立结构	IS	independent structure	两个单句在结构上彼此独立
核心关系	HED	head	指整个句子的核心

打开LTP在线demo,
输入任意句子,
自主练习

<http://www.ltp-cloud.com/>

工具演示：真实系统的句法分析结果

spaCy（英文） & HanLP（中文） 输出示例

spaCy（英文依存分析）

```
import spacy
nlp = spacy.load("en_core_web_sm")
doc = nlp("I love natural language processing")
for token in doc:
    print(token.text, token.dep_,
          token.head.text)
```

输出结果：

词	依存标签	支配词
I	nsubj	love
love	ROOT	love
natural	amod	processing
language	compound	processing
processing	dobj	love

HanLP（中文依存分析）

```
import hanlp
HanLP = hanlp.load(
    hanlp.pretrained.dep.CTB9_DEP_BIAFFINE)
result = HanLP(['张伟爱苹果'])
# 返回每个词的（词，依存头索引，关系标签）
```


输出结果：

词	头索引	依存关系	说明
张伟	2	nsubj	主语
爱	0	ROOT	谓语根
苹果	2	dobj	宾语

深度学习时代的句法分析

从手工特征到端到端神经网络

技术演进路线



Biaffine Parser 核心思想

输入词序列 → BERT/BiLSTM 编码 → 每个词得到向量表示
双仿射注意力: $\text{Score}(i \rightarrow j) = h_i^T W h_j + b_i^T h_j + h_i^T b_j$ 同时预测弧的存在性和关系类型
全局解码: 用 MST (最大生成树) 算法确保输出是合法的树结构

谢谢