

第二章 词法分析

本课程目标



理解分词的基本概念和相关方法



理解关键词提取的基本概念和相关方法



理解词性标注的基本概念和相关方法



理解命名实体识别的基本概念和相关方法

课程目录

Course catalogue

1/ 什么是词法分析

2/ 分词

3/ 关键词提取

4/ 词性标注

5/ 命名实体识别

什么是词法分析

什么是词法分析

词法分析，就是利用计算机对自然语言的形态 (morphology) 进行分析，判断词的结构和类别等，是自然语言处理中的关键组成部分。针对某种语言的词法分析与语言本身的特性相关，不能一概而论。对于中文来说，词法分析的主要任务首先是能正确地把一串连续的字符切分成一个一个的词，然后能够正确地判断每个词的词性，以便于后续的句法分析的实现。中文分词和词性标注等词法分析任务一般被统称为中文词法分析。

课程目录

Course catalogue

1/ 什么是词法分析

2/ 分词

3/ 关键词提取

4/ 词性标注

5/ 命名实体识别

中文分词技术分类

中文分词技术分类

分词算法可分为三大类：


- ① 基于词典：基于字典、词库匹配的分词方法；（字符串匹配、机械分词法）
- ② 基于统计：基于词频度统计的分词方法；
- ③ 基于规则：基于知识理解的分词方法。

第一类方法应用词典匹配、汉语词法或其它汉语语言知识进行分词，如：最大匹配法、最小分词方法等。这类方法简单、分词效率较高,但汉语语言现象复杂丰富，词典的完备性、规则的一致性等问题使其难以适应开放的大规模文本的分词处理。

第二类基于统计的分词方法则基于字和词的统计信息，如把相邻字间的信息、词频及相应的共现信息等应用于分词，由于这些信息是通过调查真实语料而取得的，因而基于统计的分词方法具有较好的实用性。


基于词典的分词

正向最大匹配分词



逆向最大匹配分词

基于词典的分词



双向最大匹配法

最大匹配分词

基于统计的分词

基于统计的分词

语言模型 (Language Model, LM) 是衡量一句自然语言句子的概率的模型

词

“你好” is more probable than “等离子体”

短语

“吃苹果” is more probable than “苹果吃”

句子

“我喝水” is more probable than “水喝我”

语言模型的定义

语言模型的定义

自然语言处理中最常见的数据是文本数据。我们可以把一段自然语言文本看作一段离散的时间序列。假设一段长度为 T 的文本中的词依次为 $w_1, w_2, \dots, w_n$ ，那么在离散的时间序列中， $w_t (1 \leq t \leq n)$ 可看作在时间步（time step） t 的输出或标签。给定一个长度为 n 的词的序列 $w_1, w_2, \dots, w_n$ ，语言模型将计算该序列的概率：

$$P(w_1, \dots, w_n)$$

语言模型的计算

语言模型的计算

假设序列 $w_1, w_2, \dots, w_n$ 中的每个词是依次生成的, 我们有

$$P(w_1, w_2, \dots, w_n) = P(w_1)P(w_2|w_1) \cdots P(w_n|w_1, \dots, w_{n-1})$$

n -gram模型概述

n -gram模型概述

然而，前面给出的计算文本序列概率的方法存在两个致命的缺陷：

参数空间过大：条件概率 $P(w_n|w_1, w_2, \dots, w_{n-1})$ 的可能性太多，无法估算，不可能有用；

数据稀疏严重：对于非常多词对的组合，在语料库中都没有出现，依据最大似然估计得到的概率将会是0。

为了解决这个问题，我们引入马尔可夫假设(Markov assumption)，即假设当前词出现的概率只依赖于前 $n - 1$ 个词，可以得到

$$P(w_i|w_1, w_2, \dots, w_{i-1}) = P(w_i|w_{i-n+1}, \dots, w_{i-1})$$

上式称为 n 元语法 (n -gram) 。当 n 分别为1、2和3时，我们将其分别称作一元语法 (unigram) 、二元语法 (bigram) 和三元语法 (trigram) 。

n -gram模型概述

n -gram模型定义

定义 n -gram语言模型如下：

unigram ($n = 1$) : $P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i)$

bigram ($n = 2$) : $P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-1})$

trigram ($n = 3$) : $P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-2}, w_{i-1})$

更大的 n ：对下一个词出现的约束信息更多，具有更大的辨别力；

更小的 n ：在训练语料库中出现的次数更多，具有更可靠的统计信息，具有更高的可靠性。

理论上， n 越大越好，经验上，trigram用的最多，尽管如此，原则上，能用bigram解决，绝不使用trigram。

通常，通过计算极大似然估计（Maximum Likelihood Estimate）构造语言模型，这是对训练数据的最佳估计，公式如下：


$$p(w_{i+1} | w_{i-k}, w_i) = \frac{c(w_{i-k}, \dots, w_i)}{c(w_{i-k}, \dots, w_{i-1})}$$

平滑技术

平滑技术

大规模数据统计方法与有限的训练语料之间必然产生数据稀疏问题，导致零概率问题，符合经典的zipf定律。人们为理论模型实用化而进行了众多尝试与努力，诞生了一系列经典的平滑技术，它们的基本思想是“降低已出现 n -gram 条件概率分布，以使未出现的 n -gram 条件概率分布非零”，且经数据平滑后一定保证概率和为1。这里我们介绍一种简单的平滑技术——加一（Add-one）平滑。加一平滑法，又称拉普拉斯定律，其保证每个 n -gram 在训练语料中至少出现1次，以bigram为例，公式如下：

$$P_{Add-1}(w_i | w_{i-1}) = \frac{c(w_{i-1}, w_i) + 1}{c(w_{i-1}) + V}$$



jieba简介

jieba 是目前使用最多的Python中文分词组件，它主要有以下 3 种特性：

- 支持 3 种分词模式：
 - ✓ 精确模式：试图将句子最精确地切开，适合文本分析；
 - ✓ 全模式：把句子中所有的可以成词的词语都扫描出来，速度非常快，但是不能解决歧义；
 - ✓ 搜索引擎模式：在精确模式的基础上，对长词再次切分，提高召回率，适合用于搜索引擎分词；
- 支持繁体分词；
- 支持自定义词典。

分词

```
1 # 全模式
2 seg_list = jieba.cut("他来到上海交通大学", cut_all=True)
3 print("【全模式】： " + "/ ".join(seg_list))
```

【全模式】： 他/ 来到/ 上海/ 上海交通大学/ 交通/ 大学

全模式

```
1 # 精确模式
2 seg_list = jieba.cut("他来到上海交通大学", cut_all=False)
3 print("【精确模式】： " + "/ ".join(seg_list))
```

【精确模式】： 他/ 来到/ 上海交通大学

精确模式

```
1 # 搜索引擎模式
2 seg_list = jieba.cut_for_search("他毕业于上海交通大学机电系，后来在一机部上海电器科学研究所工作")
3 print("【搜索引擎模式】： " + "/ ".join(seg_list))
```

【搜索引擎模式】： 他/ 毕业/ 于/ 上海/ 交通/ 大学/ 上海交通大学/ 机电/ 系/ ， / 后来/ 在/ 一机部/ 上海/ 电器/ 科学/ 研究/ 研究所/ 工作

搜索引擎模式

分词

可使用jieba.cut和jieba.cut_for_search方法进行分词，两者所返回的结构都是一个可迭代的generator，可使用for循环来获得分词后得到的每一个词语（unicode），或者直接使用jieba.lcut以及jieba.lcut_for_search直接返回list。

课程目录

Course catalogue

1/ 什么是词法分析

2/ 分词

3/ 关键词提取

4/ 词性标注

5/ 命名实体识别

什么是关键词提取

人工智能的定义

关键词提取就是从文本里面把跟这篇文章意义最相关的一些词抽取出来。这个可以追溯到文献检索初期，当时还不支持全文搜索的时候，关键词就可以作为搜索这篇论文的词语。因此，目前依然可以在论文中看到关键词这一项。除了这些以外，关键词还可以在文本聚类、分类、摘要等领域中有着重要的作用。比如在聚类时将关键词相似的几篇文章看成一个类团可以大大提K-means聚类的收敛速度。从某天所有新闻中提取出这些新闻的关键词，就可以大致知道那天发生了什么事情。或者将某段时间中几个人的微博拼成一篇长文本，然后抽取关键词就可以知道他们主要在讨论些什么话题。

Myositis is a general description for progressive inflammation of the

KEYWORD

STOPWORDS

KEYWORD

STOPWORDS

muscles. Some types of myositis are associated with skin rashes.

KEYWORD

STOPWORDS

KEYWORD

STOPWORDS

KEYWORD

TF-IDF

TF-IDF是关键词提取最基本、最简单易懂的方法。判断一个词在一篇文章中是否重要，一个容易想到的衡量指标就是词频，重要的词往往在文章中出现的频率也非常高；但另一方面，不是出现次数越多的词就一定重要，因为有些词在各种文章中都频繁出现，那它的重要性肯定不如哪些只在某篇文章中频繁出现的词重要性强。从统计学的角度，就是给予那些不常见的词以较大的权重，而减少常见词的权重。一个词的TF是指这个词在文档中出现的频率，TF计算公式如下：

$$TF_w = \frac{m}{n}$$

一个词的IDF是根据语料库得出的，表示这个词在整个语料库中出现的频率。假设整个语料库中，包含词 w 的文本一共有 M 篇，语料库中的文本一共有 N 篇，则

$$IDF_w = \log_2 \frac{N}{M}$$

由此可得词 w 的TF-IDF值为：


$$TFIDF_w = TF_w \times IDF_w$$

TF-IDF

TF-IDF的优点是实现简单，相对容易理解。但是，TF-IDF算法提取关键词的缺点也很明显，严重依赖语料库，需要选取质量较高且和所处理文本相符的语料库进行训练。另外，对于IDF来说，它本身是一种试图抑制噪声的加权，本身倾向于文本中频率小的词，这使得TF-IDF算法的精度不高。TF-IDF算法还有一个缺点就是不能反应词的位置信息，在对关键词进行提取的时候，词的位置信息，例如文本的标题、文本的首句和尾句等含有较重要的信息，应该赋予较高的权重。

基于统计特征的关键词提取算法通过上面的一些特征量化指标将关键词进行排序，获取Top K个词作为关键词。

基于统计特征的关键词的重点在于特征量化指标的计算，不同的量化指标得到的结果也不尽相同。同时，不同的量化指标作为也有其各自的优缺点，在实际应用中，通常是采用不同的量化指标相结合的方式得到Topk个词作为关键词。



TextRank

PageRank算法将整个互联网看作一张有向图，网页是图中的节点，而网页之间的链接就是途中的边。根据重要性传递的思想，如果一个网页A含有一个指向网页B的链接，那么网页B的重要性排名会根据A的重要行来提升。在PageRank算法中，对于网页初始重要值（PR值）的计算非常关键，但是这个值无法预知，于是PageRank论文中给出了一种迭代算法求出这个PR值：为每个网页随机给一个初始值，然后迭代得到收敛值，作为网页重要性的度量。

TextRank

PageRank求网页*i*的PR值的计算公式如下：

$$S(V_i) = (1 - d) + d \times \sum_{j \in In(V_i)} \frac{1}{|Out(V_j)|} S(V_j)$$

其中， d 为阻尼系数，通常为0.85， $In(V_i)$ 是指向网页*i*的网页集合， $Out(V_j)$ 是指网页*j*中的链接指向的集合， $|Out(V_j)|$ 指集合中元素的个数。

TextRank在构建图的时候将节点由网页改成了词，网页之间的链接改为词之间的共现关系，实际处理时，取一定长度的窗，在窗内的共现关系则视为有效。计算公式修改如下：

$$WS(V_i) = (1 - d) + d \times \sum_{j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j)$$

迭代得到所有词的PR值之后，就可以根据PR值的高低对词进行排序，得到文本的关键词集合。

课程目录

Course catalogue

1/ 什么是词法分析

2/ 分词

3/ 关键词提取

4/ 词性标注

5/ 命名实体识别

什么是词性标注

什么是词性标注

词性标注在自然语言处理中也属于基础性的模块，为句法分析、信息抽取等工作打下基础。和分词一样，中文词性标注也存在着很多难点，比如一词多词性，未登录词处理等诸多问题。通过基于字符串匹配的字典查询算法和基于统计的词性标注算法，可以很好的解决这些问题。一般需要先进行分词，然后再进行词性标注。




词性标注的难点

词性标注的难点

词性作为词语基本的语法属性，是词语和语句的关键性特征。词性种类也很多。词性标注中的难点主要有

- 相对于英文，中文缺少词形态变化，不能从词的形态来识别词性；
- 一词多词性很常见。统计发现，一词多词性的概率高达22.5%。而且越常用的词，多词性现象越严重。比如“研究”既可以是名词（“基础性研究”），也可以是动词（“研究计算机科学”）；
- 词性划分标准不统一。词类划分粒度和标记符号等，目前还没有一个广泛认可的统一的标准。比如LDC标注语料中，将汉语一级词性划分为33类，而北京大学语料库则将其划分为26类。词类划分标准和标记符号的不统一，以及分词规范的含糊，都给词性标注带来了很大的困难。jieba分词采用了使用较为广泛的ICTCLAS 汉语词性标注集规范。
- 未登录词问题。和分词一样，未登录词的词性也是一个比较大的课题。未登录词不能通过查找字典的方式获取词性，可以采用HMM隐马尔科夫模型等基于统计的算法。

隐马尔科夫模型



隐马尔科夫模型

实现基于HMM的词性标注方法时，模型的参数估计是其中的关键问题，通常利用词典信息约束模型的参数。假设输出符号表由单词构成，如果某个对应的“词汇—词性标记”对没有被包含在词典中，那么，就令该词的生成概率（符号发生概率）为0，否则，该词的生成概率为其可能被标记的所有词性个数的倒数，即

$$b_{j,l} = \frac{b_{i,l}^* C(w^l)}{\sum_{w^m} b_{j,m}^* C(w^m)}$$

$$b_{i,l}^* = \begin{cases} 0, & \text{如果 } l^j \text{ 不是词 } w^l \text{ 所允许的词性} \\ \frac{1}{T(w^l)}, & \text{其他情况} \end{cases}$$

隐马尔科夫模型

隐马尔科夫模型

对于词性标注任务来说,已知的单词序列 $w_1, w_2, \dots, w_m$ 为观察值序列,词性序列 $t_1, t_2, \dots, t_m$ 便为隐含着的状态序列。训练过程实际就是统计词性转移矩阵 $[a_{ij}]$ 和词性到单词的输出矩阵 b_{ij} ,而求解的过程实际上就是用维特比算法求可能性最大的状态序列。

现在假设是 W 分词后的词序列, T 是 W 某个可能的词性标注序列,其中 T^* 为最终的标注结果,即概率最大的词性序列,则有

$$W=(w_1, w_2, \dots, w_m), \quad T=(t_1, t_2, \dots, t_m), \quad T^*=\operatorname{argmax} P(T | W)$$

根据贝叶斯定理:

$$P(T | W) = \frac{P(T)P(W | T)}{P(W)}$$

则有:

$$T^*=\operatorname{argmax} \frac{P(T)P(W | T)}{P(W)}$$

隐马尔科夫模型

隐马尔科夫模型

对于一个给定的词序列,其词序列的概率 $P(W)$ 对于任意一个标记序列都是相同的,因此我们可以在计算 T^* 时忽略它,则:

进行N元语法假设,可以得出:

$$P(T)P(W|T) \approx \prod_{i=1}^m p(w_i | w_1 t_1 \cdots w_{i-1} t_{i-1}) p(t_i | w_1 t_1 \cdots w_{i-1} t_{i-1})$$

在此,我们利用二元语法模型即一阶隐马尔可夫模型,则有:

$$p(w_i | w_1 t_1 \cdots w_{i-1} t_{i-1}) = p(w_i | t_i)$$

$$p(t_i | w_1 t_1 \cdots w_{i-1} t_{i-1}) = p(t_i | t_{i-1})$$

所以:

$$T^* = \operatorname{argmax} \prod_{i=1}^m p(w_i | t_i) p(t_i | t_{i-1})$$

隐马尔科夫模型

隐马尔科夫模型

我们可以利用最大似然度估计从相对频度来估计这两个概率:

$$p(w_i | t_i) = c(w_i, t_i) / c(t_i)$$

$$p(t_i | t_{i-1}) = c(t_{i-1}, t_i) / c(t_{i-1})$$

$C(w_i | t_i)$ 是指语料库中,词 w_i 词性为 t_i 的出现次数, $C(t_i)$ 表示词性的出现次数, $C(t_{i-1} | t_i)$ 则是相邻两个词性为 t_{i-1} 和 t_i 的次数。

jieba词性标注实例

jieba词性标注实例

```
1 # 引入词性标注接口
2 import jieba.posseg as psg
3
4 text = "去北京大学玩"
5 #词性标注
6 seg = psg.cut(text)
7
8 #将词性标注结果打印出来
9 for ele in seg:
10     print(ele)
```

```
去/v
北京大学/nt
玩/v
```

不同的语言有不同的词性标注集。为了方便指明词的词性，可以给每个词性编码，jieba分词中提供了词性标注功能，可以标注标注句子分词后每个词的词性，词性标注集采用北大计算所词性标注集，属于采用基于统计模型的标注方法，下面将通过实例讲解介绍如何使用jieba分词的词性标注接口、以及通过源码讲解其实现的原理。

课程目录

Course catalogue

1/ 什么是词法分析


2/ 分词

3/ 关键词提取

4/ 词性标注

5/ 命名实体识别

什么是命名实体识别



什么是命名实体识别

命名实体识别（Named Entity Recognition, NER）是NLP里的一项很基础的任务，就是指从文本中识别出命名性指称项，为关系抽取等任务做铺垫。狭义上，是识别出人名、地名和组织机构名这三类命名实体（时间、货币名称等构成规律明显的实体类型可以用正则表达式等方式识别）。当然，在特定的领域中，会相应地定义领域内的各种实体类型。

中文命名实体识别的难点

中文命名实体识别的难点


汉语作为象形文字，相比于英文等拼音文字来说，针对中文的NER任务来说往往要更有挑战性，下面列举几点

① 中文文本里不像英文那样有空格作为词语的界限标志，而且“词”在中文里本来就是一个很模糊的概念，中文也不具备英文中的字母大小写等形态指示

② 中文的用字灵活多变，有些词在脱离上下文语境的情况下无法判断是否是命名实体，而且就算是命名实体，当其处在不同的上下文语境下也可能是不同的实体类型

③ 命名实体存在嵌套现象,而且这种现象在组织机构名中尤其严重

④ 中文里广泛存在简化表达现象，乃至简化表达构成的命名实体。



命名实体识别的方法

基于规则和词典的方法

基于规则的方法多采用语言学专家构造规则模板,选用特征包括统计信息、标点符号、关键字、指示词和方向词、位置词、中心词等方法,以模式和字符串相匹配为主要手段,这类系统大多依赖于知识库和词典的建立。基于规则和词典的方法是命名实体识别中最早使用的方法,一般而言,当提取的规则能比较精确地反映语言现象时,基于规则的方法性能要优于基于统计的方法。但是这些规则往往依赖于具体语言、领域和文本风格,编制过程耗时且难以涵盖所有的语言现象,特别容易产生错误,系统可移植性不好,对于不同的系统需要语言学专家重新书写规则。基于规则的方法的另外一个缺点是代价太大,存在系统建设周期长、移植性差而且需要建立不同领域知识库作为辅助以提高系统识别能力等问题。

命名实体识别的方法

基于统计的方法

基于统计机器学习的方法主要包括：隐马尔可夫模型、最大熵、支持向量机、条件随机场等。

在这4种学习方法中，最大熵模型结构紧凑，具有较好的通用性，主要缺点是训练时间复杂性非常高，有时甚至导致训练代价难以承受，另外由于需要明确的归一化计算，导致开销比较大。而条件随机场为命名实体识别提供了一个特征灵活、全局最优的标注框架，但同时存在收敛速度慢、训练时间长的问題。一般说来，最大熵和支持向量机在正确率上要比隐马尔可夫模型高一些，但是隐马尔可夫模型在训练和识别时的速度要快一些，主要是由于在利用维特比算法求解命名实体类别序列的效率较高。隐马尔可夫模型更适用于一些对实时性有要求以及像信息检索这样需要处理大量文本的应用,如短文本命名实体识别。

基于统计的方法对特征选取的要求较高，需要从文本中选择对该项任务有影响的各种特征，并将这些特征加入到特征向量中。依据特定命名实体识别所面临的主要困难和所表现出的特性，考虑选择能有效反映该类实体特性的特征集合。主要做法是通过对训练语料所包含的语言信息进行统计和分析，从训练语料中挖掘出特征。有关特征可以分为具体的单词特征、上下文特征、词典及词性特征、停用词特征、核心词特征以及语义特征等。

命名实体识别的方法

混合方法

自然语言处理并不完全是一个随机过程,单独使用基于统计的方法使状态搜索空间非常庞大,必须借助规则知识提前进行过滤修剪处理。目前几乎没有单纯使用统计模型而不使用规则知识的命名实体识别系统,在很多情况下是使用混合方法:

- 统计学习方法之间或内部层叠融合。
- 规则、词典和机器学习方法之间的融合,其核心是融合方法技术。在基于统计的学习方法中引入部分规则,将机器学习和人工知识结合起来。
- 将各类模型、算法结合起来,将前一级模型的结果作为下一级的训练数据,并用这些训练数据对模型进行训练,得到下一级模型。这种方法在具体实现过程中需要考虑怎样高效地将两种方法结合起来,采用什么样的融合技术。由于命名实体识别在很大程度上依赖于分类技术,在分类方面可以采用的融合技术主要包括如Voting, Grading等。

基于条件随机场的命名实体识别



条件随机场定义

条件随机场的定义：设 $X = (X_1, X_2, \dots, X_n)$ 和 $Y = (Y_1, Y_2, \dots, Y_n)$ 是联合随机变量，若随机变量 Y 构成一个无向图 $G = (V, E)$ 表示的马尔可夫模型，则条件概率分布 $P(Y | X)$ 称为条件随机场（Conditional random field, CRF），即：

$$P(Y_v | X, Y_w, w \neq v) = P(Y_v | X, Y_w, w \sim v)$$

其中 $w \sim v$ 表示图 $G = (V, E)$ 中与结点 v 有边连接的所有结点， $w \neq v$ 表示结点 v 以外的所有结点。简单举例说明：现有若干个位置组成的整体，当给某一个位置按照某种分布，随机赋一个值后，该整体就被称为随机场。

基于条件随机场的命名实体识别

条件随机场规则


当有由 n 个字符组成的NER的句子，每个字符的标签都在上面的标签集合（B,M,E,S,O）中，当为每个字符选定标签后，就形成了一个随机场，此时如果加一些约束（如所有字符的标签只和相邻的字符标签有关），那么就转换成了马尔可夫随机场问题。

标注 [↵]	含义 [↵]
B [↵]	当前词为地理命名实体的首部 [↵]
M [↵]	当前词为地理命名实体的内部 [↵]
E [↵]	当前词为地理命名实体的尾部 [↵]
S [↵]	当前词单独构成地理命名实体 [↵]
O [↵]	当前词不是地理命名实体或组成部分 [↵]

基于条件随机场的命名实体识别

规则

在马尔可夫随机场的基础上，这时如果有 X 和 Y 两种变量， X 一般是给定的， Y 是在给定 X 条件下的输出，上述的例子中， X 是字符， Y 是标签， $P(Y | X)$ 就是条件随机场。在实际自然语言处理中，多假设变量 X 和 Y 具有相同的结构




基于条件随机场的命名实体识别

线性链条件随机场

一般将这种结构称为线性链条件随机场，其定义如下：

设 $X = (X_1, X_2, \dots, X_n)$ 和 $Y = (Y_1, Y_2, \dots, Y_n)$ 均为线性链表示的随机变量序列，若在给定的随机变量序列 X 的条件下，随机序列变量 Y 的条件概率分布 $P(Y | X)$ 构成条件随机场，且满足马尔可夫性：

$$P(Y_i | X, Y_1, Y_2, \dots, Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$




$$X = X_1, \dots, X_{n-1}, X_n$$

基于条件随机场的命名实体识别

对比

HMM是一个有向图，而线性链CRF是一个无向图。因此HMM处理时，每个状态依赖上一个状态，而线性链CRF依赖于当前状态的周围结点状态。

以地名识别为例，对句子“我来到上海”进行标注，正确的标注为“我/O 来/O到/O上/B海/E”。采用CRF来进行解决，那么(O, O, O, B, E)是其中一种标注序列，(O, O, O, M, E)也是一种选择，类似的还有很多，在NER任务中就是在如此多的可选择序列中，找出最靠谱的句子的标注。



基于条件随机场的命名实体识别

标注评分

在CRF中有两种特征函数，分别是转移函数 $t_k(y_{i-1}, y_i, i)$ 和状态函数 $s_l(y_i, X, i)$ 。其中 $t_k(y_{i-1}, y_i, i)$ 依赖于当前和前一位置，表示从标注序列中位置 $(i - 1)$ 的标记 y_{i-1} 转移到位置 (i) 上的标记为 y_i 的概率。 $s_l(y_i, X, i)$ 依赖于当前位置，表示标记序列在位置 i 上标记为 y_i 的概率。并通过取值为1或者0，表示符不符合该条规则的约束。

下面是完整的线性链CRF参数化形式：

$$P(y|x) = \frac{1}{Z(x)} \exp\left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, i) + \sum_{i,l} u_l s_l(y_i, X, i)\right)$$

其中：

$$Z(x) = \sum_y \exp\left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, i) + \sum_{i,l} u_l s_l(y_i, X, i)\right)$$

$Z(x)$ 是规范化因子，其求和是在所有可能的输出序列上求和。 λ_k 和 u_l 为转移函数和状态函数对应的权值。在经过化简和合并将上式改为下式：

$$P(y|x) = \frac{1}{Z(x)} \exp\left(\sum_j \sum_i w_j f_j(y_{i-1}, y_i, x, i)\right)$$

相比于HMM，CRF能够捕捉全局的信息，并能进行灵活的特征设计。

结束

谢谢