

第五章 课堂互动

深度学习与神经网络

选择题

以下哪个激活函数可以有效缓解梯度消失问题？

Sigmoid

Tanh

ReLU



Softmax

答案: C — ReLU

Sigmoid 和 Tanh 的导数在两端趋近于 0，多层叠加后梯度指数级衰减（梯度消失）

ReLU: $f(x) = \max(0, x)$ ，正区间导数恒为 1，梯度不会衰减

Softmax 是输出层归一化函数，不是隐藏层激活函数

选择题

ReLU 激活函数的主要缺陷是什么？如何改进？

输出不是 zero-centered → 改用 Tanh

负区间输出恒为 0（神经元死亡）→ 改用 Leaky ReLU / GELU



计算量太大 → 改用 Sigmoid

只能用于输出层 → 改用 Softmax

答案: B 当输入 < 0 时 ReLU 输出恒为 0，梯度也为 0，神经元永远无法更新（Dead ReLU）。Leaky ReLU 在负区间给一个小斜率 ($0.01x$)，GELU 则用高斯概率平滑过渡。

计算题

一个单隐藏层网络，输入 $x = [1, 2]$ ，计算输出

已知条件:

隐藏层权重 $W1 = [[0.5, -0.3], [0.2, 0.8]]$ 偏置

$b1 = [0.1, -0.1]$

输出层权重 $W2 = [[0.6], [0.4]]$ 偏置 $b2 =$

$[0.2]$

激活函数: ReLU (隐藏层)

提示

前向传播三步走:

1. 线性变换 $z = xW + b$
2. 激活函数 $h = f(z)$
3. 下一层重复

先自己动手算!

解题步骤:

① $z1 = x \cdot W1 + b1 = [1 \times 0.5 + 2 \times 0.2 + 0.1, 1 \times (-0.3) + 2 \times 0.8 + (-0.1)] = [1.0, 1.2]$

② $h1 = \text{ReLU}(z1) = [\max(0, 1.0), \max(0, 1.2)] = [1.0, 1.2]$

③ **output = $h1 \cdot W2 + b2 = 1.0 \times 0.6 + 1.2 \times 0.4 + 0.2 = 1.28$**

判断题 — 对 or 错?

反向传播算法的核心是链式法则 (Chain Rule) , 它从输出层到输入层逐层计算梯度。

对 ✓

错 ✗

答案: 对 ✓

反向传播的本质就是链式法则的递归应用:

$$\partial L / \partial w = \partial L / \partial y \cdot \partial y / \partial z \cdot \partial z / \partial w$$

从输出层的损失开始, 沿计算图反方向, 逐层将梯度传回每个参数。
梯度流动方向与前向传播相反, 所以叫“反向”传播。

选择题

对于一个 10 类图片分类任务，应该选择哪种损失函数？

均方误差 (MSE)

交叉熵损失 (Cross-Entropy)



二元交叉熵 (Binary CE)

Hinge Loss

答案: B — 交叉熵损失

$L = -\sum y_i \log(\hat{y}_i)$ (y_i 是 one-hot 标签, $\hat{y}_i$ 是 softmax 输出)

MSE 用于回归任务，不适合分类（梯度在 softmax 输出接近 0/1 时非常小）

Binary CE 用于二分类，Hinge Loss 用于 SVM。多分类用交叉熵 + Softmax 是标配。

判断题 — 对 or 错?

Dropout 在训练和测试时的行为完全相同，都会随机关闭一些神经元。

对 ✓

错 ✗

答案: 错 ✗

训练时: 以概率 p 随机关闭神经元 (输出置 0)，迫使网络不依赖任何单一特征

测试时: 所有神经元都参与计算，但输出要乘以 $(1-p)$ 来补偿训练时的丢弃

PyTorch 中: `model.train()` 启用 Dropout, `model.eval()` 关闭 Dropout

选择题

Batch Normalization 的主要作用不包括以下哪项?

加速训练收敛

减少内部协变量偏移

增大模型参数量来提升表达力



允许使用更大的学习率

答案: c

BN 的核心是对每层输入做标准化 (均值 $\rightarrow 0$, 方差 $\rightarrow 1$), 再通过可学习参数 γ, β 恢复表达力。
 γ 和 β 只是两个标量参数, 几乎不增加模型参数量。BN 的好处是训练更稳定、收敛更快、可用更大学习率。

讨论题

你的模型训练集准确率 99%，测试集只有 65%，发生了什么？你会怎么解决？

现象分析

训练准确率 >> 测试准确率

这是典型的过拟合（Overfitting）
模型记住了训练数据的噪声

解决方案（课堂讨论）

- ① Dropout — 随机丢弃神经元
- ② L2 正则化 — 惩罚大权重
- ③ 数据增强 — 扩充训练集
- ④ Early Stopping — 监控验证集
- ⑤ 减小模型容量（层数/宽度）

追问：如果训练集和测试集准确率都很低（比如都是 55%），又是什么问题？

→ 欠拟合（Underfitting）：模型太简单，无法学到数据规律。解决方法：增加模型容量、训练更久、降低正则化强度。

课堂互动结束

有问题随时提问！